Ciencia de datos, práctica 1

Juan Casado Ballesteros

October 11, 2019

Abstract

En esta práctica vamos a realizar tres análisis estadísticos, en los dos primeros utilizaremos las funciones propias de R sobre los datos proporcionados por el profesor en los formatos .txt para el primero y .sav para el segundo. En el tercer análisis hemos programado nosotros mismos nuestras propias funciones. Como datos hemos elegido un .csv que contiene información sobre el alquiler en la Ciudad de Nueva York. Intentaremos para este tercer análisis realizar un estudio crítico que nos permita llegar a conocer los datos con los que estamos trabajando.

Contents

1 Primer análisis satelites menores de urano.txt

Comenzamos leyendo los datos del archivo .txt ya que dicho archivo lo hemos escrito con la sintaxis que textbfread.table espera por lo que no tendremos que utilizar ningún parámetro adicional para configurar la lectura de los datos.

```
> source("init.R")
> satelites <- read.table("./satelites.txt")
```

Primero calcularemos la frecuencia absoluta de los datos, que es el número de apariciones de cada uno de ellos.

```
> frecuencia_absoluta<-table(satelites$radio)
```

Ahora calcularemos la frecuencia absoluta acumulada.

```
> frecuencia_absoluta_acumulada<-cumsum(frecuencia_absoluta)
```

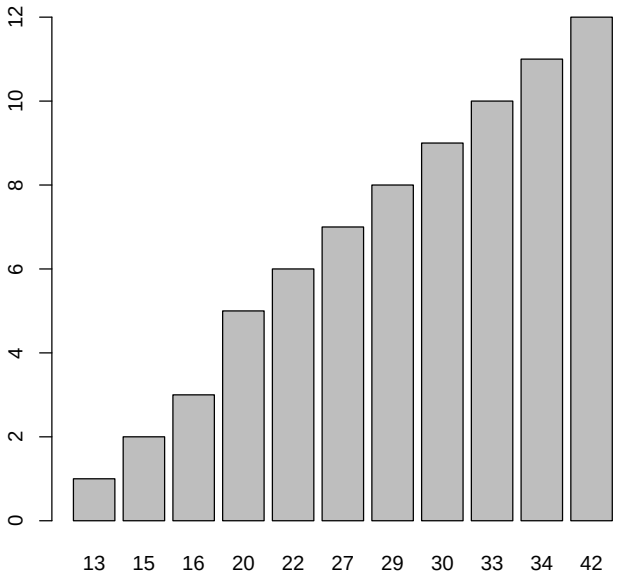

Ahora calcularemos la frecuencia relativa.

```
> frecuencia_relativa <- (function(data) table(data)/length(data))(satelites$radio)
> sum(frecuencia_relativa)

[1] 1
```

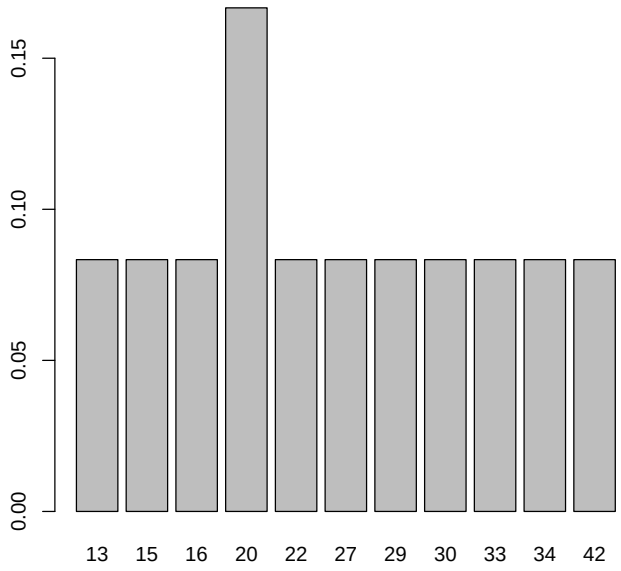

Ahora calcularemos la frecuencia relativa acumulada.

```
> frecuencia_relativa_acumulada <- cumsum(frecuencia_relativa)
```

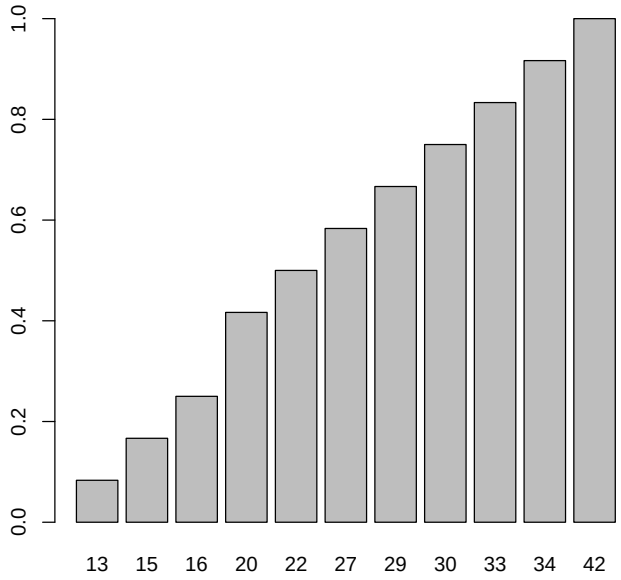

Calcularemos a continuación estadísticos cuya función es resumir los datos de los que disponemos. Estos estadísticos son la media, la moda y la mediana.

```
> media <- mean(satelites$radio)
> v_mediana <- median(satelites$radio)
> v_moda <- moda(satelites$radio)
> desviacion_tipica <- sd(satelites$radio)
> v_varianza <- var(satelites$radio)
```

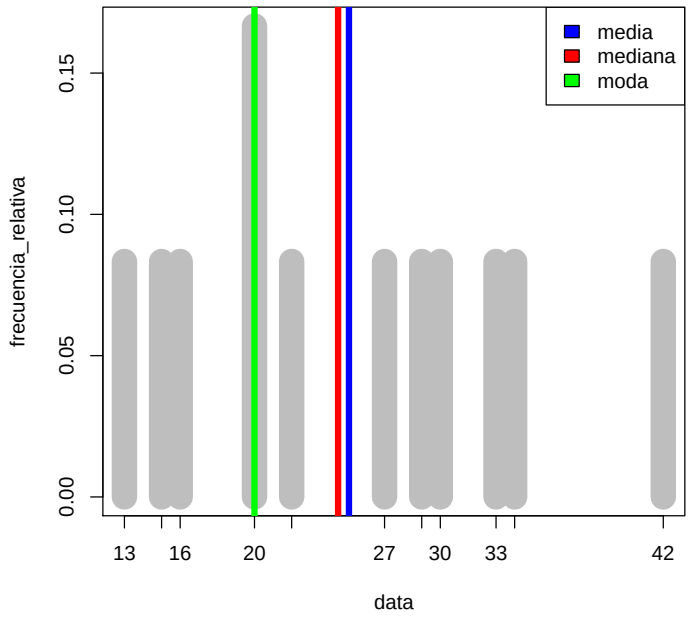


```
> desviacion_tipica

[1] 8.857029

> v_varianza

[1] 78.44697
```

Cuantiles y cuartiles ...

```
> v_cuartiles <- quantile(satelites$radio, prob=c(0, .25, .5, .75, 1))
> v_cuantil54 <- quantile(satelites$radio, prob=(.54))
```

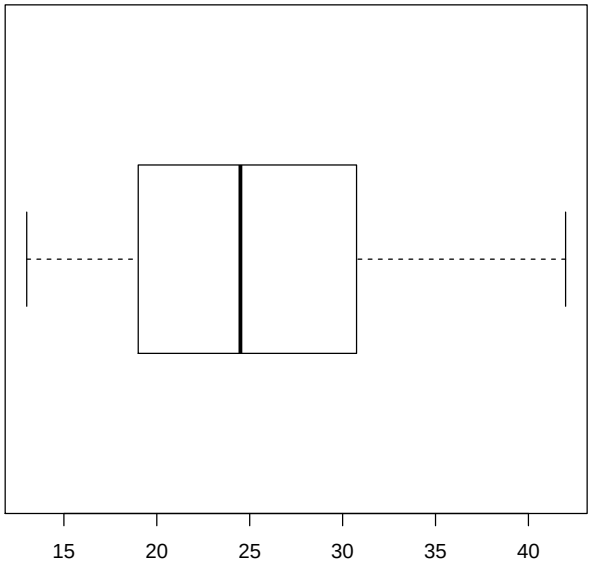


```
> v_cuartiles

   0%   25%   50%   75%  100%
13.00 19.00 24.50 30.75 42.00

> v_cuantil54

 54%
26.7
```

2 Segundo análisis cardata .sav

```
> source("init.R")
> cardata <- read.spss("./cardata.sav")$mpg
> cardata <- cardata[!is.na(cardata)]

> mean(cardata)

[1] 28.79351

> median(cardata)

[1] 28.9

> moda(cardata)

[1] 36
```

```
> sd(cardata)

[1] 7.37721

> var(cardata)

[1] 54.42323
```

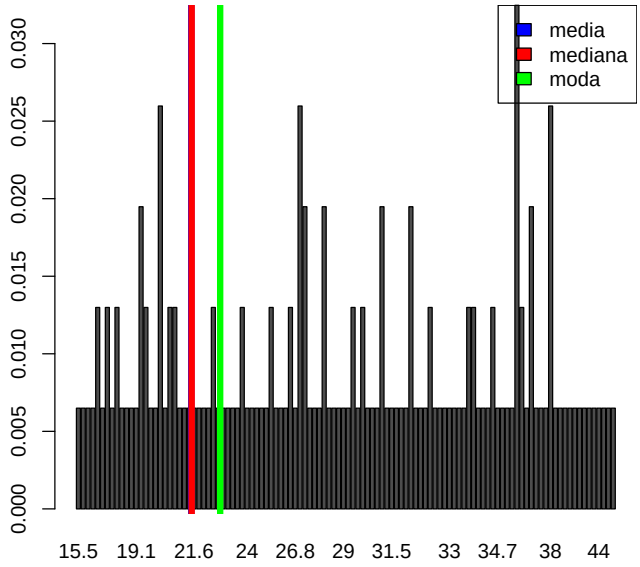


```
> v_cuartiles <- quantile(cardata, prob=c(0, .25, .5, .75, 1))
> v_cuartiles

    0%    25%    50%    75%   100%
15.500 22.550 28.900 34.275 46.600
```

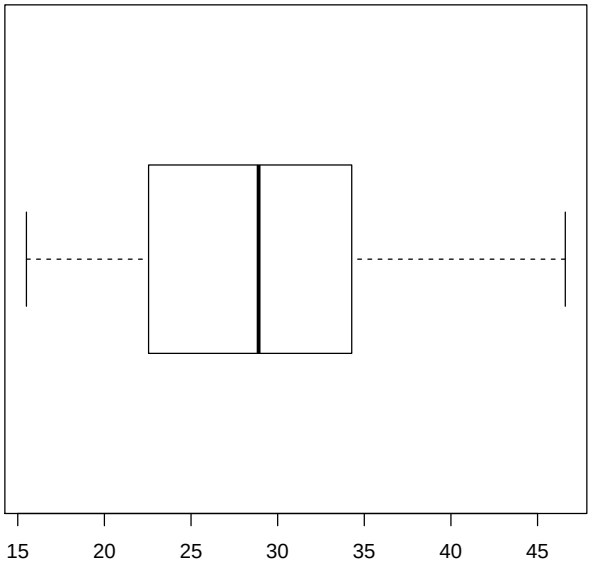

3 Tercer análisis del alquiler en Nueva York con AirBNB durante 2019 .csv

Haremos ahora un análisis de los datos del alquiler en la ciudad de Nueva York durante el año 2019 con la compañía AirBNB. Los datos contienen las siguientes categorías:

```
> getInfo(data)

                                unlist.res.
id                                  integer
name                                 factor
host_id                             integer
host_name                            factor
neighbourhood_group                  factor
neighbourhood                        factor
latitude                            numeric
longitude                           numeric
room_type                            factor
price                               integer
minimum_nights                      integer
number_of_reviews                   integer
last_review                          factor
reviews_per_month                   numeric
calculated_host_listings_count      integer
```

```
availability_365                    integer
res_frame
 factor integer numeric
      6       7       3
```

Comenzaremos por analizar el precio de los alquileres. Para ello calcularemos la frecuencia relativa de los precios.

```
> frecuencia_relativa<-frecuenciaRelativa(data$price)
```

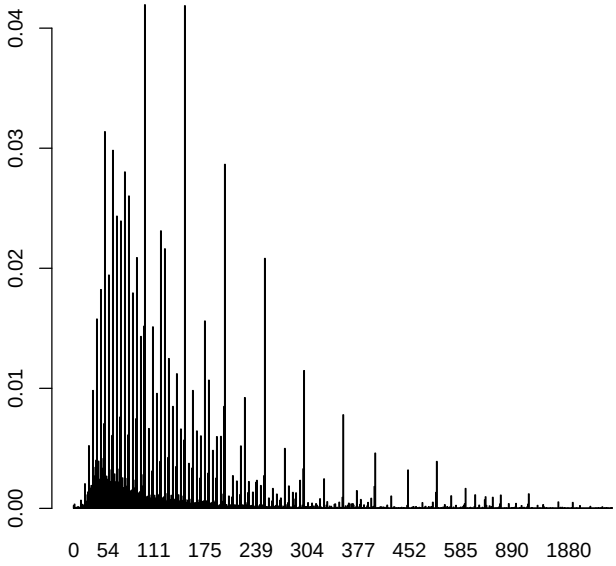

Podemos observar que los precios están muy agrupados en la parte izquierda de la gráfica (precios bajos) con altos porcentajes de aparición, no obstante aunque con una densidad mucho menor estos se alejan en gran medida llegando a alcanzar precios muy elevados pero con pocos porcentajes de aparición.

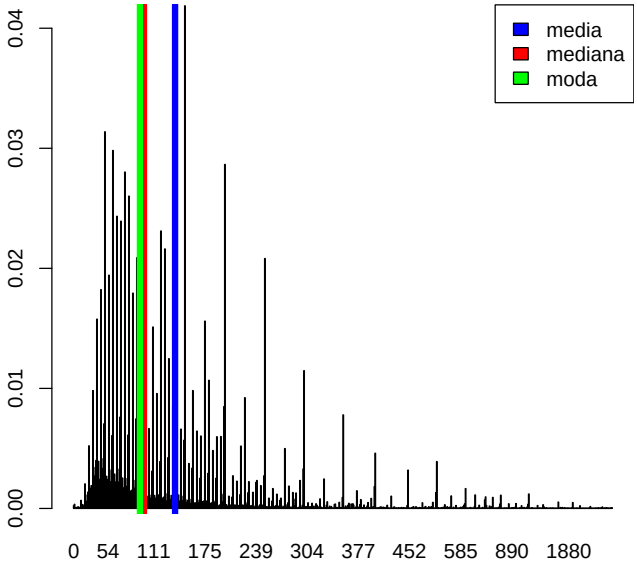


```
> v_cuartiles <- cuartiles(data$price)
```

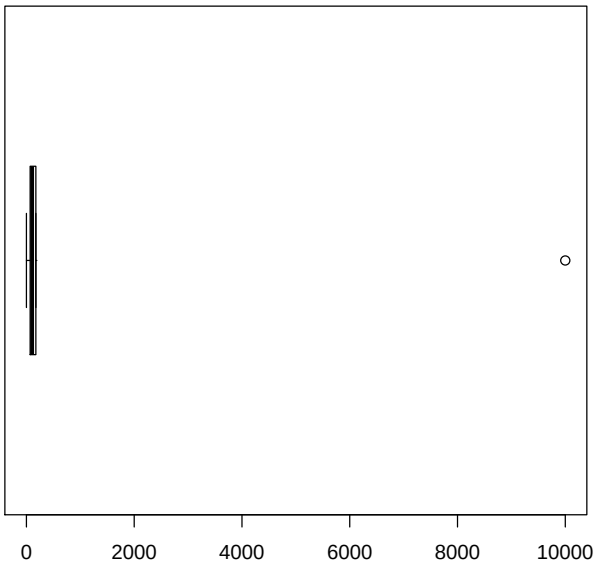

Vemos que la media no es un valor representativo, su desviación típica es muy

alta. Podemos observar como la moda y la mediana en este caso parecen representar mejor a la mayoría de los datos. Debido a esto decidimos que hacer el análisis de los precios para toda la ciudad no iba a aportarnos una visión representativa de los datos. Decidimos ahora calcular el precio medio por cada barrio en vez de hacerlo sobre toda la ciudad a la vez.

	Group.1	x.media	x.desviacion_tipica	x.mediana	x.moda
1	Bronx	87.49679	106.66043	65.00000	60.00000
2	Brooklyn	124.38321	186.86889	90.00000	100.00000
3	Manhattan	196.87581	291.37646	150.00000	150.00000
4	Queens	99.51765	167.08741	75.00000	50.00000
5	Staten Island	114.81233	277.24801	75.00000	75.00000

Valores sobre el total de los datos sin haber separado por barrios

media	desviacion_tipica	v_mediana	v_moda
152.7207	240.1517	106.0000	100.0000

Podemos ver que la varianza se ha reducido para más barrios de en los que ha aumentado. En Bronx es en el barrio en el que tanto la varianza como la media es menor y Manhattan es en el que ambas son mayores.
Datos para Manhattan

```
> manhattan_data = data$price[data$neighbourhood_group == "Manhattan"]
> plotFrecuencyData(manhattan_data)
```

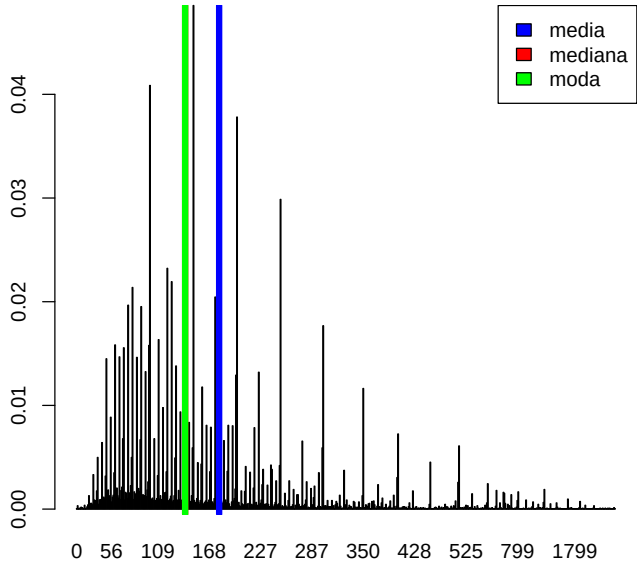

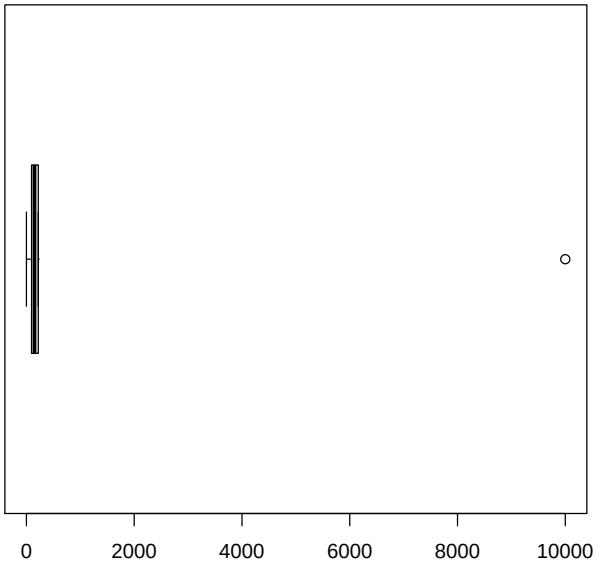

Datos para Bronx

```
> bronx_data <- data$price[data$neighbourhood_group == "Bronx"]
> plotFrecuencyData(bronx_data)
```

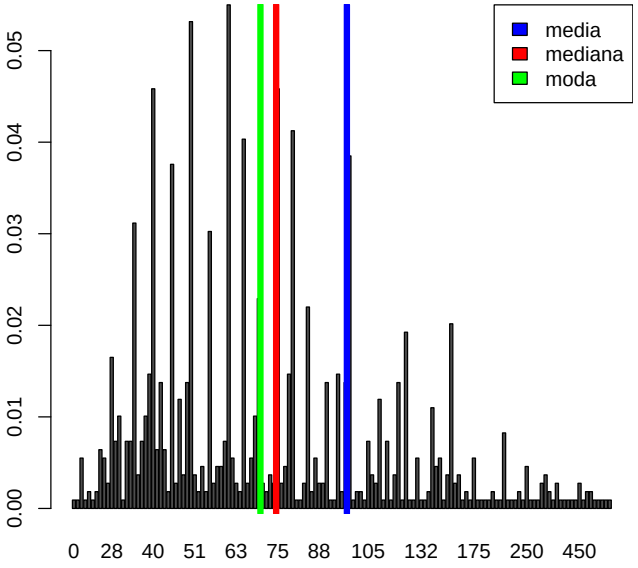

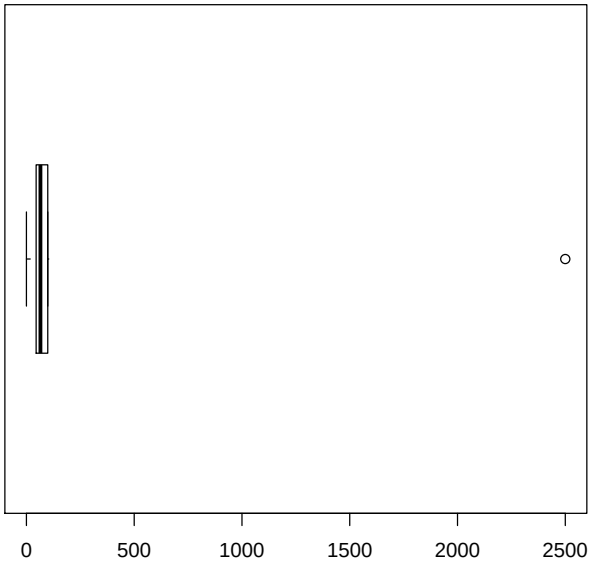

Datos para Brooklyn

```
> brooklyn_data <- data$price[data$neighbourhood_group == "Brooklyn"]
> plotFrecuencyData(brooklyn_data)
```

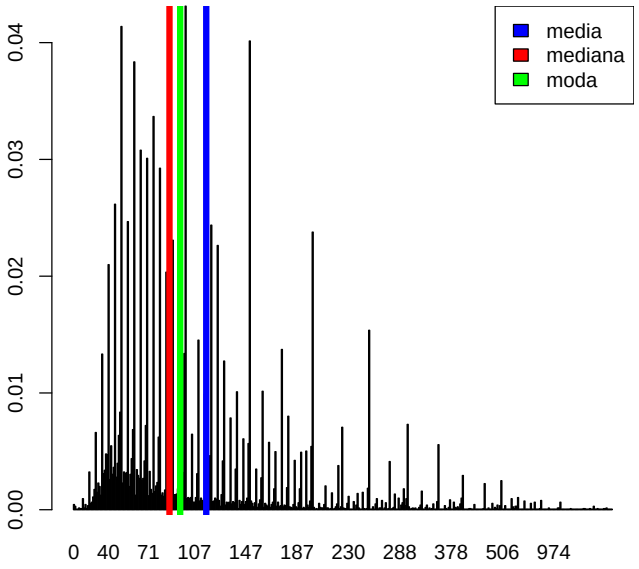

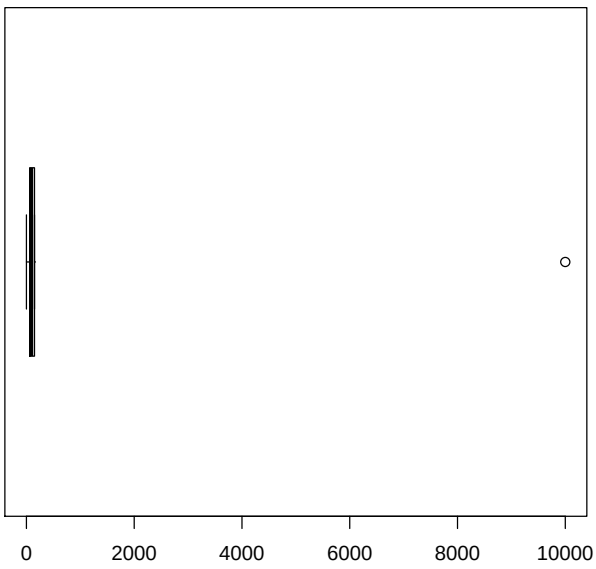

Datos para Queens

```
> queens_data <- data$price[data$neighbourhood_group == "Queens"]
> plotFrecuencyData(queens_data)
```

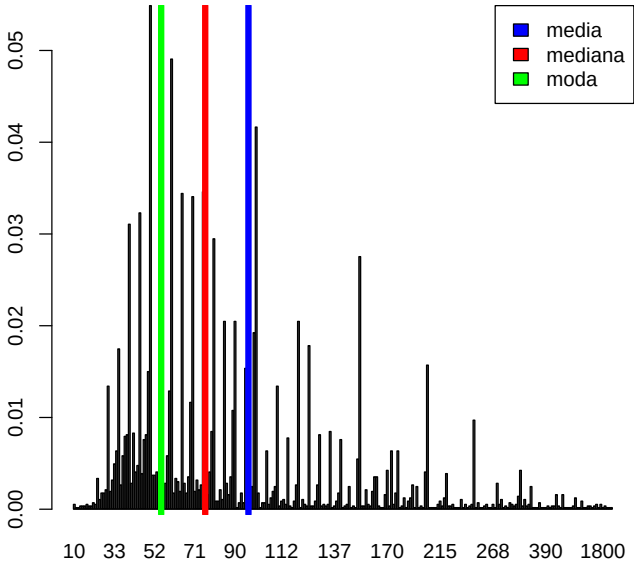

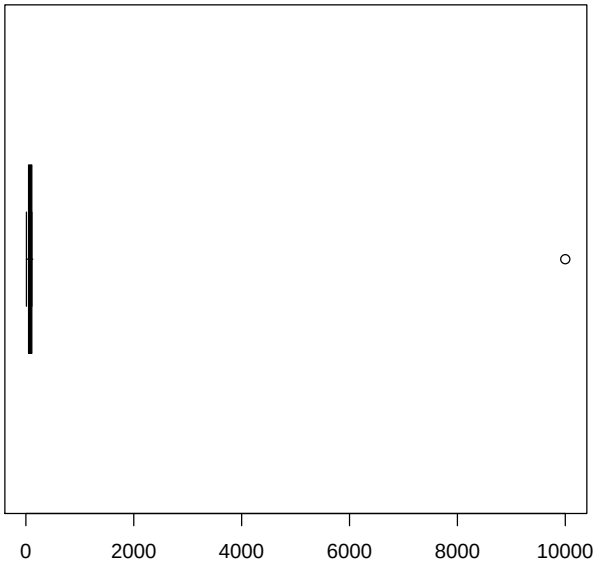

Datos para Staten Island

```
> state_data <- data$price[data$neighbourhood_group == "Staten Island"]
> plotFrecuencyData(state_data)
```

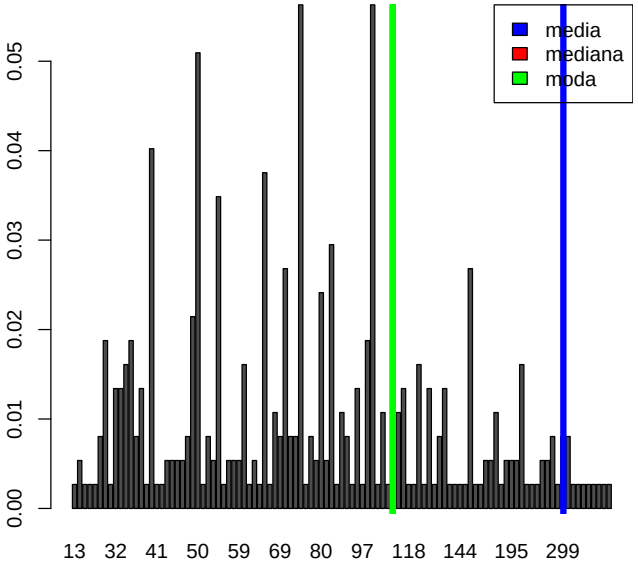
media
mediana
moda
0.00
0.01
0.02
0.03
0.04
0.05
13
32
41
50
59
69
80
97
118
144
195
299

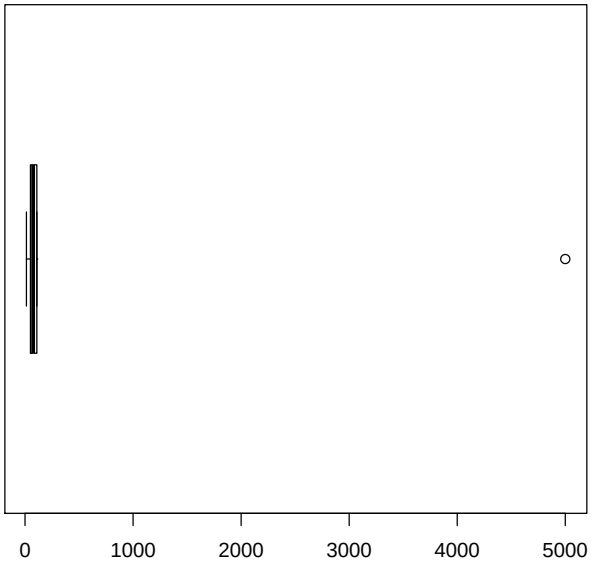
0
1000
2000
3000
4000
5000

4 Guia en R para el análisis estadístico

4.1 Frecuencias

```
> Frecuencia_absoluta <- table(data)
> Frecuencia_absoluta_acumulada <- cumsum(frecuencia_absoluta)
> Frecuencia_relativa <- (function(data) table(data)/length(data))(data)
> Frecuencia_relativa_acumulada <- cumsum(frecuencia_relativa)
```

4.2 Medidas representativas

```
> Media <- mean(data)
> Desviacion_tipica <- sd(data)
> Varianza <- var(data)
```

4.3 Medidas de ordenación

```
> Mediana <- median(data)
> Cuartiles <- quantile(data, prob=c(0, .25, .5, .75, 1))
> Cuantil54 <- quantile(data, prob=(.54))
```

5 Funciones creadas

5.1 Frecuencias

5.1.1 Frecuencia Absoluta

```
> frecuenciaAbsoluta
```

```
function(data){
  # creamos un vector donde solo estas los elementos sin repetir
  uniquedata<-unique(data)
  # ordenamos el vector para aparezco correcto
  uniquedata<- sort(uniquedata)
  # creamos un vector vacio numerico
  newdata<- vector(mode="numeric", length=0)
  # recorremos el vector elementos no repetidos
  for (value in uniquedata) {
    # calculamos la cantidad de veces que se repite un numero
    total<-length(data[data==value])
    # añadimos el total al vector con veces que se repitio
    newdata<-c(newdata, total)
  }
  # hacemos una matriz de tamaño 1xlongitud datos, añadimos los elementos la frecuencia
  matrix<-matrix(nrow=1,ncol=length(uniquedata), newdata, byrow=T)
  # en las filas ponemos el nombre que representa
  rownames(matrix)<-c("frecuencia")
  #en las columnas ponemos los datos
  colnames(matrix)<-c(uniquedata)
  #convertimos la matriz en una tabla
  matrix<-as.table(matrix)
```

```
}
<bytecode: 0x7fba7757ba50>
```

5.1.2 Frecuencia Absoluta Acumulada

> frecuenciaAbsolutaAcumulada

```
function(data){

    # calculamos la frecuencia
    frecuencia <-frecuenciaAbsoluta(data)
    # recuperamos el nombre de las columnas
    uniquedata<-colnames(frecuencia)
    # cogemos el vector de frecuencia
    onlydata<-frecuencia[1,]
    # creamos un vector vacio numerico
    newdata<- vector(mode="numeric", length=0)
    # recorremos desde la posicion 1 hasta lo maximo el vector
    for (value in 1:length(onlydata)) {
        # si el valor primero
        if(value==1){
            # el acumulado es el mismo valor
            accumulated<-onlydata[value]
        # en otros casos
        }else{
            # el valor es anterior mas el valor suyo
            accumulated<-onlydata[value]+accumulated
        }
        # añadimos al vector el nuevo valor
        newdata<-c(newdata, accumulated)
    }
    # hacemos una matriz de tamaño 1xlongitud datos, añadimos los elementos la frecuencia
    matrix<-matrix(nrow=1,ncol=length(uniquedata), newdata, byrow=T)
    # en las filas ponemos el nombre que representa
    rownames(matrix)<-c("frecuencia acumulada")
    #en las columnas ponemos los datos
    colnames(matrix)<-c(uniquedata)
    #convertimos la matriz en una tabla
    matrix<-as.table(matrix)
}
```

5.1.3 Frecuencia Relativa

> frecuenciaRelativa

```
function(data){
    #conseguimos frecuencia
    frecuencia <-frecuenciaAbsoluta(data)
    # recuperamos el nombre de las columnas
    uniquedata<-colnames(frecuencia)
    #cogemos solo el vector de frecuencia
```

```
    onlydata<-frecuencia[1,]
    #calculamos la suma total de frecuencia
    total<-sum(onlydata)
    #creo vector vacio numerico
    newdata<- vector(mode="numeric", length=0)
    #recorro todo el vector de datos
    for (value in 1:length(onlydata)) {
        # realizamos la division entre los datos y el total
        accumulated<-onlydata[value]/total
        # lo añado al nuevo array
        newdata<-c(newdata, accumulated)
    }
    # hacemos una matriz de tamaño 1xlongitud datos, añadimos los elementos la frecuencia
  matrix<-matrix(nrow=1,ncol=length(uniquedata), newdata, byrow=T)
  # en las filas ponemos el nombre que representa
  rownames(matrix)<-c("frecuencia relativa")
  #en las columnas ponemos los datos
  colnames(matrix)<-c(uniquedata)
  #convertimos la matriz en una tabla
  matrix<-as.table(matrix)
}
<bytecode: 0x7fba76f98f08>
```

5.1.4 Frecuencia Relativa Acumulada

```
> frecuenciaRelativaAcumulada

function(data){
    # calcumos la frecuencia acumulada
    frecuencia <-frecuenciaAcumulada(data)
    # recuperamos el nombre de las columnas
    uniquedata<-colnames(frecuencia)
    # cogemos el vector de frecuencia acumulada
    onlydata<-frecuencia[1,]
    # calculamos el total de datos
    total<-onlydata[length(onlydata)]
    # creamos un vector vacio numerico
    newdata<- vector(mode="numeric", length=0)
    # recorremos desde la posicion 1 hasta lo maximo el vector
    for (value in 1:length(onlydata)) {
        #variable que calcula relativa entre la esa posicion entre total
        relative<-onlydata[value]/total
        # añadimos al vector el nuevo valor
        newdata<-c(newdata, relative)
    }
    # hacemos una matriz de tamaño 1xlongitud datos, añadimos los elementos la frecuencia
  matrix<-matrix(nrow=1,ncol=length(uniquedata), newdata, byrow=T)
  # en las filas ponemos el nombre que representa
  rownames(matrix)<-c("frecuencia acumulada relativa")
  #en las columnas ponemos los datos
```

```
  colnames(matrix)<-c(uniquedata)
  #convertimos la matriz en una tabla
  matrix<-as.table(matrix)
}
```

5.2 Medidas representativas

5.2.1 Media Aritmetica

```
> mediaAritmetica

function(data){
  acc <- 0
  for (value in data) {
    acc <- acc + value
  }
  acc / length(data)
}
<bytecode: 0x7fba72420098>
```

5.2.2 Media Geométrica

```
> mediaGeometrica

function(data){
  prod(data)^(1/length(data))
}
```

5.2.3 Media Armónica

```
> mediaArmonica

function(data){
  1/mean(1/data)
}
```

5.2.4 Desviacion Típica

```
> desviacionTipica

function (data) {
  varianza(data)^(1/2)
}
<bytecode: 0x7fba75728b18>
```

5.2.5 Desviacion Media

```
> desviacionMedia

function (data){
  v_media <- media(data)
  acc = 0
  for (value in data){
```

```
    acc <- acc + abs(value - v_media)
  }
  acc/length(data)
}
```

5.2.6 Varianza

```
> varianza
```

```
function(data){
  v_media <- mediaAritmetica(data)
  acc = 0
  for (value in data){
    acc <- acc + (value - v_media)^2
  }
  acc/length(data)
}
<bytecode: 0x7fba7531db48>
```

5.2.7 Tchebychev

```
> tchebychev
```

```
function(data, limit=10){
  desviacion_tipica = desviacionTipica(data)
  for (k in 2:limit){
    data_percentage <- (1-(1/k^2))*100
    radious = desviacion_tipica*k
    message(paste("En un radio de",radious,"se encuentran el",data_percentage,"de los dato
  }
}
```

5.3 Medidas de ordenación

5.3.1 Mediana

```
> mediana
```

```
function(data){
  x = sort(data)
  size = length(x)
  if (size  %% 2 == 0){
    (x[size / 2] + x[(size / 2) +1]) / 2.0
  }
  else {
     x[size / 2]
  }
}
<bytecode: 0x7fba74e29ae0>
```

5.3.2 Cuartiles

```
> cuartiles

function(data){
    x = sort(data)
    size = length(x)
    if (size  %% 2 == 0){
        c(
            x[1],
            (x[size / 4] + x[(size / 4) +1]) / 2.0 ,
            (x[size / 2] + x[(size / 2) +1]) / 2.0 ,
            (x[size *0.75] + x[size * 0.75 + 1]) / 2.0,
            x[size]
        )

    }
    else {
        c(
            x[1],
            x[size / 4],
            x[size / 2],
            (x[size *0.75] + x[size * 0.75 + 1]) / 2.0,
            x[size]
        )
  }

}
<bytecode: 0x7fba73bcbe90>
```

5.3.3 Cuantil54

```
> cuantil54

function(x){
  size = length(x)
  x[ceiling(size*0.54)]
}
```