Ciencia de datos, práctica 2

Juan Casado Ballesteros, Samuel García Gonzalez, Iván Anaya Martín October 21, 2019

Abstract

Para esta práctica vamos a investigar los algoritmos de asociación. Utilizaremos apriori para analizar cestas de la compra y datos de vehículos. Posterioremente explicaremos como funciona el algoritmo de apriori y proporcionaremos un pequeño manual sobre cómo utilizarlo.

Para la parte final aplicaremos el algoritmo apriori sobre conjuntos de datos reales. También estudiaremos otros algoritmos que calculen la asociación (eclat) y compararemos sus resultados respecto de los de apriori. Para estos otros algoritmos haremos también un manual sobre cómo utilizarlos.

A lo largo del documento añadiremos gráficas que nos permitirán visualizar los resultados de forma más conveniente. Para ello hemos utilizado el paquete arulesViz.

Contents

1	Asociación sobre los datos de las cestas de la compra	3				
	1.1 Cargar los datos de un .txt	3				
	1.2 Llamar a apriori					
	1.3 Calcular asociación	4				
2	Asociación sobre los datos de los vehículos	6				
3	Qué es apriori y cómo utilizarlo					
4	Creación de un algoritmo apriori	9				
5	Apriori sobre un dataset real	10				
6	Otros algoritmos de asociación	15				
	6.1 Que es eclat y cómo utilizarlo	15				
	6.1.1 Ejemplos de con eclat	15				

1 Asociación sobre los datos de las cestas de la compra

Hemos introducido los datos de las cestas de la compra en un fichero .txt para evitar tener que escribirlos varias veces. Utilizamos funciones que hemos creado para automatizar la lectura del fichero y también para utilizar el algoritmo apriori. En estas funciones solo realizamos una lectura y una ejecición del algoritmo con los parámetros que nosotros hemos elegido. En el fichero .txt guardamos los elementos como listas de la compra en horizonal y los transformamos a como la función que llama a apriori espera recibirlos. En la función que llama a apriori configuramos como queremos utilizar el algoritmo de modo que no se nos impriman los detalles de su ejecución ni se calculen las asociaciones con conjuntos vacíos.

1.1 Cargar los datos de un .txt

Convierte la matriz a datos booleanos y la transpone, nos es más fácil escribir los datos en horizontal y transponer que no escribirlos ya como se espera que estén.

```
> readAprioriFile
function(file){
  muestra<-Matrix(as.matrix(read.table(file)), sparse=T)
  muestrangCMatrix<-as(muestra,"nsparseMatrix")
  t(muestrangCMatrix)
}</pre>
```

1.2 Llamar a apriori

Con minlen=2 indicamos que no queremos calcular asociaciones con el conjunto vacío y con verbose=F que nos queremos obtener el progreso del algoritmo.

```
> calapriori
function(matrix,soporte,confianza){
    transacciones<-as(matrix,"transactions")
    asociaciones <- apriori(transacciones,
        parameter=list(minlen=2, support=soporte,confidence=confianza),
        control=list(verbose=F))
    inspect(asociaciones)
    asociaciones
}</pre>
```

1.3 Calcular asociación

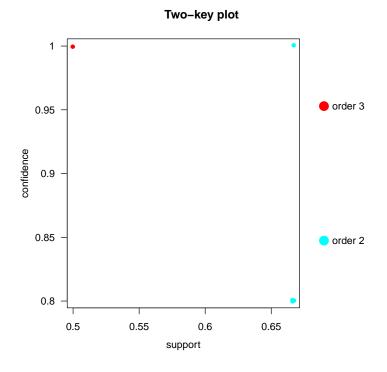
Calculamos la asociación con soporte $0.5~\mathrm{y}$ confianza $0.8~\mathrm{para}$ los datos de las cestas de la compra.

> shop_data = calapriori(readAprioriFile("datos1.txt"),0.5,0.8)

	lhs		rhs	support	confidence	lift	count
[1]	{Agua}	=>	{Pan}	0.6666667	1.0	1.20	4
[2]	{Pan}	=>	{Agua}	0.6666667	0.8	1.20	4
[3]	{Leche}	=>	{Pan}	0.6666667	0.8	0.96	4
[4]	{Pan}	=>	{Leche}	0.6666667	0.8	0.96	4
[5]	{Agua,Leche}	=>	{Pan}	0.5000000	1.0	1.20	3

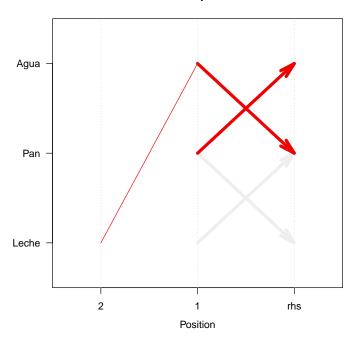
Como podemos observar en el resultado de la ejecución del algoritmo apriori, en la muestra de datos es común que, por ejemplo, en la misma cesta de la compra, si se ha comprado agua y leche, se compra también pan. Lo mismo sucede entre pan y agua (en ambas direcciones) y leche y pan (en ambas direcciones) aunque con una confianza menor.

> plot(shop_data, method = "two-key plot")



> plot(shop_data, method = "paracoord", control = list(reorder = TRUE))

Parallel coordinates plot for 5 rules



> plot(shop_data, method = "graph")

Size: support (0.5 – 0.667) color: lift (0.96 – 1.2) Leche Pan Agua

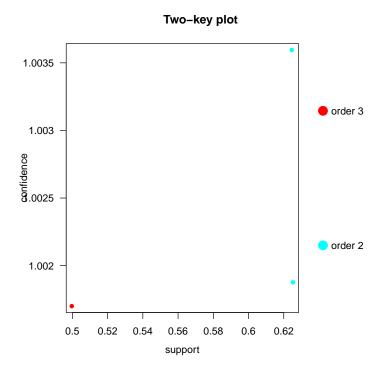
2 Asociación sobre los datos de los vehículos

Ya habíamos creado las función para leer datos de un .txt y suministrárselos a apriori. Repetimos el proceso ahora con los datos de los automóbiles iobteniendo los siguentes resultados para un soporte de 0.4 y una confianza de 0.9.

> car_data <<- calapriori(readAprioriFile("datos2.txt"),0.4,0.9)</pre>

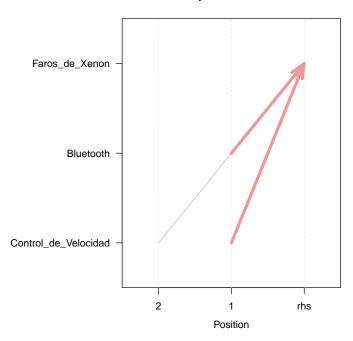
Observamos tras ejecutar el algoritmo que los coches que poseen control de velocidad y bluetooth por separado tienen faros de xenon y en conjunto también los tienen, pero con menor soporte.

> plot(car_data, method = "two-key plot")



> plot(car_data, method = "paracoord", control = list(reorder = TRUE))

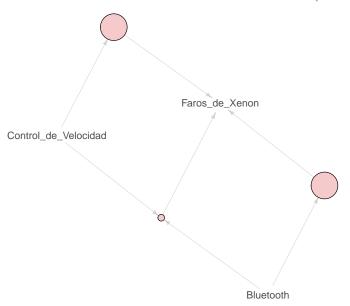
Parallel coordinates plot for 3 rules



> plot(car_data, method = "graph")

Graph for 3 rules

size: support (0.5 – 0.625) color: lift (1.333 – 1.333)



3 Qué es apriori y cómo utilizarlo

El algoritmo a priori surge como respuesta al problema existente a la hora de analizar las reglas de asociación entre diferentes datos, puesto que con unas decenas de datos diferentes podemos encontrar miles de reglas diferentes y el principio en el que se basa es que si un conjunto de datos es frecuente, cualquier subconjunto del mismo también lo será. Este algoritmo encuentra reglas de asociación entre diferentes datos en base a dos parámetros que establecemos arbitrariamente que tienen que cumplirse en ellas, que son el soporte y la confianza. El soporte de un conjunto de datos se define como la proporción de apariciones que contiene dicho conjunto de datos en el espacio muestral. La confianza define la probabilidad de encontrar relacionadas una parte derecha de una regla de asociación con una parte izquierda determinadas.

Invocamos la función escribiendo apriori() y los diferentes parámetros que nos interesan para su uso son los siguientes: Apriori(data, parameter = NULL, appearance = NULL, control = NULL) Data: estructura de datos (por ejemplo, una matriz binaria o un data.frame) que se puede convertir en transacciones. Parameter: diferentes parámetros de la clase APparameter. El comportamiento por defecto de los parámetros importantes es: soporte (support) de 10Appearance: diferentes parámetros de la clase APappearance. Con esto podemos restringir la aparición de algunos datos. Control: diferentes parámetros de la clase APcontrol. Controla el rendimiento del algoritmo (sort, heap, filter...) y aspectos como la ordenación o el reporte del rendimiento (verbose).

4 Creación de un algoritmo apriori

Hemos programado una versión simplificada del algoritmo eliminando algunas de las optimizaciones que este realiza. La funcionalidad de nuestro algoritmo también es reducida y solo está pensado para tomar como entrada tablas de datos booleanos a diferencia del apriori original que puede tomar otros tipos de dato como entrada. Para implementarlo lo hemos hecho utilizando tres funciones.

Repetimos el cálculo de la asociación para los datos de las cestas de la compra y de los automóbiles comprobando que nuestro algoritmo proporciona los mismos resultados que apriori nos había dado anteriormente. Comprobamos que el algoritmo se comporta como esperábamos.

> print(toTable(f_apriori(readAprioriFile("datos1.txt"),0.5,0.8)),right=F)

```
lhs
                                      confidence lift count
                   rhs
                           support
1 {Pan}
                => {Agua}
                           0.6666667 0.8
                                                 1.20 4
2 {Agua}
                => {Pan}
                           0.6666667 1.0
                                                 1.20 4
3 {Pan}
                                                 0.96 4
                => {Leche} 0.6666667 0.8
                           0.6666667 0.8
4 {Leche}
                => {Pan}
                                                 0.96 4
5 {Agua, Leche} => {Pan}
                           0.5000000 1.0
                                                 1.20 3
```

> print(toTable(f_apriori(readAprioriFile("datos2.txt"),0.4,0.9)),right=F)

5 Apriori sobre un dataset real

Buscando información sobre el algoritmo apriori y sobre otros algoritmos de asociación hemos encontrado distintas fuentes de las que obtener datos típicos sobre los que aplicar algoritmos de asociación. Hemos elegido un conjunto de datos que están ya incluidos en el paquete arules para probar sobre ellos el comportamiento del algoritmo.

Podemos observar que la asociación puede aplicarse también sobre variables con múltiples valores, no solo verdadero o falso. Los datos contienen 8993 observaciones en 14 variables. El primer paso para procesarlos es crear clases de equivalencia (2) para cada valor. Una vez hecho esto solo nos queda crear las transacciones y proporcionárselas al algoritmo apriori.

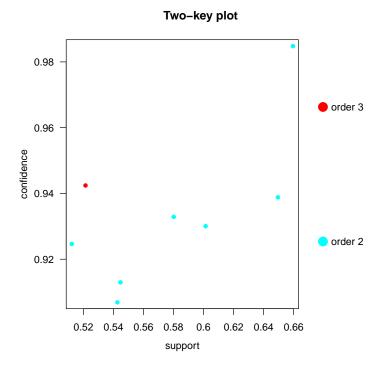
```
> data("IncomeESL")
```

> income <- calapriori(IncomeESL, 0.5,0.9)</pre>

```
lhs
                                                                   support confidence
[1] {sex=female}
                                  => {language in home=english} 0.5122164
                                                                           0.9246521 1.012
[2] {type of home=house}
                                  => {language in home=english} 0.5446481
                                                                            0.9129693 1.000
[3] {dual incomes=not married}
                                  => {language in home=english} 0.5426120
                                                                           0.9069033 0.993
[4] {number of children=0}
                                  => {language in home=english} 0.5801338
                                                                           0.9328812 1.021
[5] {years in bay area=10+}
                                  => {language in home=english} 0.6013671
                                                                            0.9300495 1.018
[6] {ethnic classification=white} => {language in home=english} 0.6595404
                                                                            0.9847991 1.078
[7] {number in household=1}
                                  => {language in home=english} 0.6495055
                                                                           0.9388270 1.028
[8] {number in household=1,
                                  => {language in home=english} 0.5213787 0.9424290 1.032
    number of children=0}
```

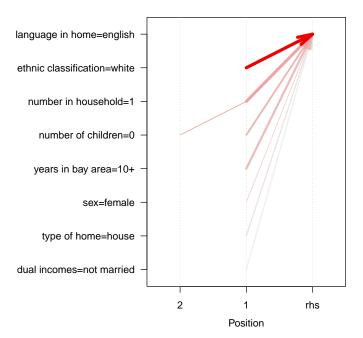
hay un gran conjunto de datos en la muestra que tienen alto soporte y confianza en que hablen en Ingles en casa.

```
> plot(income, method = "two-key plot")
```



> plot(income, method = "paracoord", control = list(reorder = TRUE))

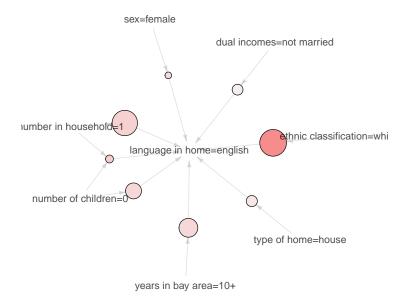
Parallel coordinates plot for 8 rules



> plot(income, method = "graph")

Graph for 8 rules

size: support (0.512 - 0.66) color: lift (0.993 - 1.079)

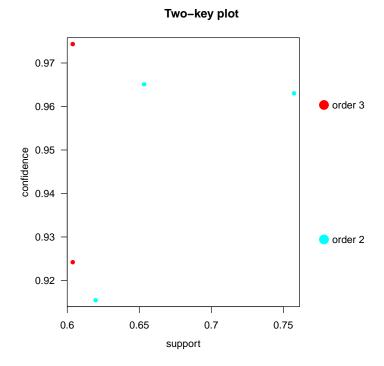


Haremos ahora el mismo proceso sobre datos de los supervivientes del titanic. En este caso, los datos encontrados ya están en formato de transacciones tay y como apriori los espera.

```
> load("./titanic.raw.rdata")
> titanic_data <- apriori(titanic.raw,</pre>
       parameter=list(minlen=2, support=0.5,confidence=0.8),
        control=list(verbose=F))
> inspect(titanic_data)
   lhs
                                                                          count
                                           support
                                                     confidence lift
[1] {Survived=No}
                            => {Sex=Male} 0.6197183 0.9154362 1.163995 1364
[2] {Survived=No}
                            => {Age=Adult} 0.6533394 0.9651007 1.015386 1438
[3] {Sex=Male}
                            => {Age=Adult} 0.7573830 0.9630272 1.013204 1667
[4] {Sex=Male,Survived=No} => {Age=Adult} 0.6038164 0.9743402 1.025106 1329
[5] {Age=Adult,Survived=No} => {Sex=Male} 0.6038164 0.9242003 1.175139 1329
```

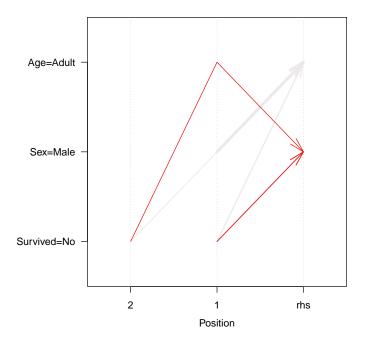
Podemos ver que los primeros en salvarse fueron las mujeres y los niños.

```
> plot(titanic_data, method = "two-key plot")
```



> plot(titanic_data, method = "paracoord", control = list(reorder = TRUE))

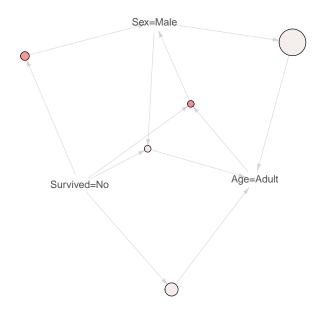
Parallel coordinates plot for 5 rules



> plot(titanic_data, method = "graph")

Graph for 5 rules

size: support (0.604 – 0.757) color: lift (1.013 – 1.175)



6 Otros algoritmos de asociación

6.1 Que es eclat y cómo utilizarlo

Eclat es una alternativa a apriori que utiliza para cada elemento una lista en la que se registra en qué transacción está el elemento mencionado, reduciendo así enormemente el tiempo de cómputo, pero aumentando el consumo de memoria. La idea básica es que usa estas listas y realiza intersecciones con otras para calcular el soporte del elemento, evitando generar subconjuntos que no existan en el espacio muestral.

Invocamos la función escribiendo eclat() y los diferentes parámetros que nos interesan para su uso son los siguientes: Eclat(data, parameter = NULL, control = NULL) Data: estructura de datos (por ejemplo, una matriz binaria o un data.frame) que se puede convertir en transacciones. Parameter: diferentes parámetros de la clase ECparameter. El comportamiento por defecto de los parámetros importantes es: soporte (support) de 10Control: diferentes parámetros de la clase ECcontrol. Controla el rendimiento del algoritmo (sort, heap, filter...) y aspectos como la ordenación o el reporte del rendimiento (verbose).

6.1.1 Ejemplos de con eclat

Ejecución sobre la muestra de los datos de las cestas de la compra.

> caleclat(readAprioriFile("datos1.txt"),0.5)

```
items support count
[1] {Pan,Agua,Leche} 0.5000000 3
[2] {Pan,Agua} 0.6666667 4
[3] {Agua,Leche} 0.5000000 3
[4] {Pan,Leche} 0.6666667 4
set of 4 itemsets
```

Ejecución sobre la muestra de los datos de los componentes de los coches.

> caleclat(readAprioriFile("datos2.txt"),0.4)

	items	support	count
[1]	{Faros_de_Xenon,Bluetooth,Control_de_Velocidad}	0.500	4
[2]	{Faros_de_Xenon,Control_de_Velocidad}	0.625	5
[3]	{Bluetooth,Control_de_Velocidad}	0.500	4
[4]	{Faros_de_Xenon,Bluetooth}	0.625	5
set	of 4 itemsets		

Ejecución sobre la muestra de los datos demográficos incluídos en el paquete arules.

> caleclat(IncomeESL, 0.5)

	items	support	count
[1]	{sex=female,		
	<pre>language in home=english}</pre>	0.5122164	3522
[2]	{age=14-34,		
	<pre>language in home=english}</pre>	0.5248691	3609

```
[3] {type of home=house,
     language in home=english}
                                      0.5446481 3745
[4]
    {dual incomes=not married,
     language in home=english}
                                      0.5426120
                                                 3731
   {number in household=1,
     number of children=0,
     language in home=english}
                                      0.5213787
                                                 3585
    {number of children=0,
     language in home=english}
                                      0.5801338
                                                 3989
[7] {number in household=1,
     number of children=0}
                                      0.5532286
                                                 3804
    \{income = \$0 - \$40,000,
     language in home=english}
                                      0.5578825
                                                 3836
    \{income = \$0 - \$40,000,
      education=no college graduate} 0.5018906
                                                 3451
[10] {years in bay area=10+,
      language in home=english}
                                      0.6013671 4135
[11] {ethnic classification=white,
      language in home=english}
                                      0.6595404
                                                4535
[12] {number in household=1,
      ethnic classification=white}
                                      0.5001454
                                                3439
[13] {number in household=1,
      language in home=english}
                                      0.6495055
                                                 4466
[14] {education=no college graduate,
      language in home=english}
                                      0.6343805 4362
set of 14 itemsets
```

Ejecución sobre la muestra de los datos de los supervivientes del titanic.

	items	support	count
[1]	{Sex=Male,Age=Adult,Survived=No}	0.6038164	1329
[2]	{Age=Adult,Survived=No}	0.6533394	1438
[3]	{Sex=Male,Survived=No}	0.6197183	1364
۲4٦	{Sex=Male.Age=Adult}	0.7573830	1667

Podemos observar que obtenemos el mismo soporte que con apriori y que tal y como hemos dicho la confianza no es calculada. Para compara los resultados de apriori con los de eclat debemos buscar en apriori los conjuntos que se correspondan con los de eclat.

Ej: los conjuntos de apriori: {Pan} => {Agua} y {Agua} => {Pan} en eclat serán solo uno: {Pan, Agua}